

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ
УНИВЕРСИТЕТ имени М.В. ЛОМОНОСОВА»

МЕХАНИКО-МАТЕМАТИЧЕСКИЙ ФАКУЛТЕТ

КАФЕДРА ТЕОРИИ УПРУГОСТИ

КУРСОВАЯ РАБОТА

специалиста

Применение обратимых нейронных сетей для идентификации параметров
многослойной упругой полосы

Application of invertible neural networks to identify the parameters of
a multilayer elastic strip

Выполнил студент
525 группы
Леонов Иван Алексеевич

подпись студента.

Научный руководитель:
к.ф.-м.н., доцент
Бобылев Александр Александрович

подпись научного руководителя.

Москва 2026

Содержание

1	Постановка прямой задачи	3
1.1	Сеточные функции контактных усилий и постановка обратной задачи	5
1.2	Параметризация упругих свойств полосы	5
1.3	Формулировка обратной задачи	6
2	Нейросетевой аппроксиматор	6
2.1	Алгоритм работы	6
2.2	Архитектура обратимых нейронных сетей	7
2.2.1	Решение проблемы несовпадения размерностей	8
2.2.2	Функция потерь и метод максимального правдоподобия	8
2.2.3	Эффективное вычисление якобиана	8
2.2.4	Построение многослойной обратимой архитектуры	9
2.3	Подготовка данных	10
3	Численные решения.	10
3.1	Решение прямой задачи с помощью	10
3.1.1	Архитектура модели	11
3.1.2	Результаты обучения	11
3.2	Обратимые нейронные сети без латентного пространства	12
3.2.1	Архитектура	12
3.2.2	Результаты обучения	12
3.3	Обратимые нейронные сети с латентным пространством	13
3.3.1	Метод главных компонент	13
3.3.2	Архитектура	14
3.3.3	Результаты обучения	14

Введение

Задача идентификации параметров многослойной упругой полосы по данным индентирования представляет собой актуальную проблему механики деформируемого твёрдого тела. Многослойные структуры, характеризующиеся ступенчатым изменением упругих модулей и толщин отдельных слоёв, широко применяются в современных инженерных конструкциях, однако их дискретная неоднородность существенно усложняет восстановление механических и геометрических характеристик по экспериментальным или численным данным контактного взаимодействия. Прямая задача коллективного индентирования, описывающая связь между набором параметров слоёв и нормализованными контактными усилиями, решается эффективно, тогда как обратная задача является некорректно поставленной и требует применения специализированных подходов.

В последнее время для решения обратных задач всё шире применяются нейросетевые модели, обладающие способностью аппроксимировать сложные нелинейные зависимости. Тем не менее, традиционные архитектуры не обеспечивают свойство обратимости и взаимно-однозначного соответствия. Альтернативой выступают обратимые нейронные сети (Invertible Neural Networks, INN), которые реализуют биективное отображение между пространством параметров слоёв и пространством наблюдаемых контактных данных. Такие сети допускают точное аналитическое обращение, что может быть критически важно для устойчивого решения обратных задач идентификации.

Основное внимание в работе уделено численной реализации алгоритма решения задачи идентификации параметров четырехслойной упругой полосы и сравнению различных подходов: классического многослойного персептрона для прямой задачи, обратимых сетей без латентного пространства и архитектур с введением латентных переменных для компенсации несовпадения размерностей пространства параметров слоёв и размерности наблюдаемых данных.

1 Постановка прямой задачи

Пусть невесомая многослойная упругая полоса в прямоугольной декартовой системе координат Ox_1x_2 занимает область

$$\Omega = \{\mathbf{x} = (x_1, x_2) \in \mathbb{R}^2 : 0 \leq x_2 \leq h, |x_1| \leq \infty\} \quad (1)$$

и состоит из N упругих слоёв Ω_n , границы раздела которых параллельны оси Ox_1 . Слои пронумерованы от 1 до N в порядке возрастания координаты x_2 . Слой Ω_n , $n = \overline{1, N}$ имеет толщину h_n и является однородным и изотропным со значениями модулей Юнга и коэффициентов Пуассона E_n и ν_n (рис. 2).

Под $u_I^{(n)}(\mathbf{x})$, $\sigma_{IJ}^{(n)}(\mathbf{x})$, $I, J = 1, 2$ будем понимать соответственно компоненты вектора перемещений и тензора напряжений в точке $\mathbf{x} \in \Omega_n$.

Предполагается, что упругая полоса находится в условиях плоской деформации, деформации малы, а массовые силы и напряжения в недеформированном состоянии отсутствуют.

Границу полосы $x_2 \equiv 0$ обозначим через Γ_0 , границу $x_2 \equiv h_1 + \dots + h_n$ раздела слоёв Ω_n и Ω_{n+1} — через Γ_n , $n = \overline{1, N-1}$, а границу полосы $x_2 \equiv h$ — через Γ_N . Напряжённо-деформированное состояние слоев Ω_n , $n = \overline{1, N-1}$ описывается системой уравнений:

$$\boldsymbol{\varepsilon} = \text{def } \mathbf{u}, \quad \boldsymbol{\sigma} = \mathbf{S} : \boldsymbol{\varepsilon}, \quad \text{div } \boldsymbol{\sigma} = \mathbf{0} \quad \text{в } \Omega_n, \quad (2)$$

где $\text{def} = \frac{1}{2}(\text{grad} + \text{grad}^T)$.




Рис. 1: Система штампов




Рис. 2: Схема четырехслойной полосы

Вдоль границы Γ_0 полоса соединена с недеформируемым основанием. В случае полного сцепления граничные условия имеют вид:

$$u_1 = u_2 = 0 \quad \text{на } \Gamma_0. \quad (3)$$

На границах раздела слоёв также задаются условия полного сцепления:

$$u_1^{(n)} = u_1^{(n+1)}, \quad u_2^{(n)} = u_2^{(n+1)}, \quad \sigma_{12}^{(n)} = \sigma_{12}^{(n+1)}, \quad \sigma_{22}^{(n)} = \sigma_{22}^{(n+1)} \quad \text{на } \Gamma_n, \quad n = \overline{1, N-1}. \quad (4)$$

Рассматривается задача о вдавливании системы гладких жёстких штампов Π_k , $k = \overline{1, K}$, упруго связанных с общей жёсткой платформой Π_0 , в полосу (рис. 1). Требуется определить поля напряжений в упругом теле при заданных геометрических параметрах системы, механических характеристиках полосы и внешних нагрузках

Штампы Π_k соединены с платформой Π_0 линейными упругими пружинами Λ_k с коэффициентами податливости $c_k > 0$. Штамп Π_k может поступательно перемещаться без трения вдоль прямолинейных направляющих платформы, параллельных оси Ox_2 в исходном состоянии. Относительное перемещение штампа Π_k вдоль направляющих платформы Π_0 обозначается δ_k ; положительные значения δ_k соответствуют сжатию пружины.

Положение платформы Π_0 как жёсткого целого определяется вектором перемещений $\delta^0 = (\delta_1^0, \delta_2^0)$ и углом поворота φ_3^0 . Перемещения платформы и штампов, а также угол поворота платформы предполагаются малыми.

Часть границы Γ , по которой возможен контакт полосы со штампами, обозначается Γ^p . Предполагается, что Γ^p является конечной односвязной областью и может быть представлена в виде объединения непересекающихся подобластей Γ_k , соответствующих основаниям отдельных штампов:

$$\Gamma^p = \bigcup_{k=1}^K \Gamma_k, \quad \Gamma_k \cap \Gamma_j = \emptyset \quad (k \neq j). \quad (5)$$

Введём на Γ^p :

$$\delta(x_1) = \sum_{k=1}^K \delta_k \chi_k(x_1), \quad (6)$$

где $\chi_k(x_1)$ — характеристическая функция области Γ_k .

Линеаризованные условия одностороннего гладкого контакта на Γ^p имеют вид:

$$\begin{aligned} u_2 &\leq \Phi + \delta_2^0 + \delta - (x_1 - x_1^c) \varphi_3^0, \\ \sigma_{22} &\leq 0, \quad \sigma_{12} = 0, \\ \sigma_{22} [u_2 - \Phi - \delta_2^0 - \delta + (x_1 - c_1) \varphi_3^0] &= 0 \end{aligned} \quad (7)$$

, где x_1^c — координата центра приведения платформы.

Остальная часть границы свободна от внешних нагрузок:

$$\sigma_{21} = \sigma_{22} = 0 \quad \text{на } \Gamma \setminus \Gamma^p. \quad (8)$$

Уравнения равновесия жёстких штампов Π_k имеют вид

$$c_k \int_{\Gamma_k} \sigma_{22} d\Gamma = -\delta_k, \quad k = \overline{1, K}. \quad (9)$$

Уравнения равновесия жёсткой платформы Π_0 имеют вид:

$$\int_{\Gamma^p} \sigma_{22} d\Gamma = F_2, \quad \int_{\Gamma^p} (x_1 - x_1^c) \sigma_{22} d\Gamma = M_3, \quad (10)$$

где $F_2 < 0$ — заданная нормальная компонента главного вектора внешних сил, M_3 — заданный главный момент относительно центра приведения.

Для выделения класса единственности решения в рассматриваемой контактной задаче используется условие конечности потенциальной энергии деформации многослойной упругой полосы:

$$\int_{\Omega} \sigma : \varepsilon d\Omega < \infty. \quad (11)$$

1.1 Сеточные функции контактных усилий и постановка обратной задачи

Для формулировки обратной задачи введём сеточную функцию нормализованных контактных усилий $\mathbf{R} = [r_k]_{k=1}^K$, определяемую как

$$r_k = \frac{1}{|F_2|} \int_{\Gamma_k} p(x_1) d\Gamma, \quad k = \overline{1, K}, \quad (12)$$

где $p(x_1) = -\sigma_{22}(x_1) \geq 0$ — распределение контактного давления на Γ^p , $F_2 < 0$ — заданная нормальная компонента главного вектора внешних сил. Компонента r_k характеризует долю суммарного контактного усилия, приходящуюся на область Γ_k , соответствующую штампу Π_k . По определению выполняется условие нормировки $\sum_{k=1}^K r_k = 1$.

Значения сеточной функции $\mathbf{R}$ вычисляются путём численного решения прямой задачи коллективного индентирования с использованием алгоритма, разработанного в работе [1]. В работе будут рассматриваться семейства штампов с $K = 8$.

1.2 Параметризация упругих свойств полосы

Для описания неоднородных упругих свойств полосы используются безразмерные функции модуля Юнга $E(x_2)$ и коэффициента Пуассона $\nu(x_2)$, где

$$E(x_2) = \frac{\tilde{E}(x_2)}{E^*}, \quad E^* = 1 \text{ МПа}, \quad (13)$$

$\tilde{E}(x_2)$ — размерный модуль Юнга, E^* — характерный масштаб для обезразмеривания. Будут рассматриваться задачи с параметрами из заданных диапазонов: $E \in [0.2, 3]$, $\nu \in [0.1, 0.45]$.

Рассматриваются четырёхслойные полосы (рис. 2), ввиду чего распределения $E(x_2)$ и $\nu(x_2)$ полностью определяются вектором

$$\mathbf{X} = (E_1, E_2, E_3, E_4, \nu_1, \nu_2, \nu_3, \nu_4) \in \mathbb{R}^8. \quad (14)$$

1.3 Формулировка обратной задачи

Прямая задача задаёт отображение

$$\mathcal{F}_{\text{direct}} : \mathbf{X} \mapsto \mathbf{R}, \quad (15)$$

сопоставляющее набор упругих параметров $\mathbf{X}$ сеточной функции нормализованных контактных усилий $\mathbf{R}$.

Обратная задача: по измеренной при помощи алгоритма [1] сеточной функции $\mathbf{R}$ восстановить вектор параметров $\mathbf{X}$. Решение задачи будет осуществляться с использованием нейросетевого аппроксиматора, обученного на выборке пар $(\mathbf{X}, \mathbf{R})$, полученных в результате многократного решения прямой задачи алгоритмом [1].

Для формирования обучающей выборки параметров $\mathbf{X}$ используется метод латинского гиперкуба (Latin Hypercube Sampling, LHS) [7], обеспечивающий равномерное покрытие допустимой области параметров.

2 Нейросетевой аппроксиматор

2.1 Алгоритм работы

Рассмотрим структуру классической многослойной нейронной сети или многослойного персептрона. Пусть задана выборка $\mathbf{X} = \{\mathbf{x}_i \in \mathbb{R}^d \mid i = 1, \dots, M\}$ и соответствующие целевые значения $\mathbf{Y} = \{\mathbf{y}_i \in \mathbb{R}^k \mid i = 1, \dots, M\}$. В качестве модели численного решения задачи строится оператор $\mathcal{F}_\theta : \mathbb{R}^d \rightarrow \mathbb{R}^k$, реализуемый многослойным персептроном:

$$\begin{aligned} \boldsymbol{\xi}^{(0)} &= \mathbf{x}, \quad \mathbf{x} \in \mathbf{X}; \\ \boldsymbol{\xi}^{(\ell)} &= \phi^{(\ell)}(\mathbf{W}^{(\ell)} \boldsymbol{\xi}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad \ell = 1, \dots, N-1; \\ \hat{\mathbf{y}} &= \mathcal{F}_\theta(\mathbf{x}) = \phi^{(N)}(\mathbf{W}^{(N)} \boldsymbol{\xi}^{(N-1)} + \mathbf{b}^{(N)}), \end{aligned} \quad (16)$$

где N — количество слоёв сети (задаётся априори), $\phi^{(\ell)}$ — известные аналитически функции активации, $\mathbf{W}^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}}$ и $\mathbf{b}^{(\ell)} \in \mathbb{R}^{n_\ell}$ — матрицы весов и векторы смещений соответственно. Совокупность всех обучаемых параметров обозначается $\theta = \{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_{\ell=1}^N$, т.о. получаем выражение $\hat{\mathbf{y}} = \mathcal{F}_\theta(\mathbf{x})$.

Задача обучения сводится к минимизации функционала потерь $\mathcal{L}$ на обучающей выборке:

$$\theta^* = \arg \min_{\theta} \frac{1}{M} \sum_{i=1}^M \mathcal{L}(\mathcal{F}_\theta(\mathbf{x}_i), \mathbf{y}_i). \quad (17)$$

В данной работе в качестве $\mathcal{L}$ используется среднеквадратичная ошибка:

$$\mathcal{L}(\hat{\mathbf{y}}_i, \mathbf{y}_i) = \frac{1}{k} \sum_{j=1}^k (y_{ij} - \hat{y}_{ij})^2. \quad (18)$$

Оптимизация параметров осуществляется методом стохастического градиентного спуска или его модификациями. На каждом шаге t параметры обновляются по правилу:

$$\mathbf{W}_{t+1}^{(\ell)} = \mathbf{W}_t^{(\ell)} - \alpha \nabla_{\mathbf{W}_t^{(\ell)}} \mathcal{L}, \quad (19)$$

$$\mathbf{b}_{t+1}^{(\ell)} = \mathbf{b}_t^{(\ell)} - \alpha \nabla_{\mathbf{b}_t^{(\ell)}} \mathcal{L}, \quad (20)$$

где $\alpha > 0$ — шаг обучения, t — номер итерации. Градиенты вычисляются с помощью алгоритма обратного распространения ошибки:

$$\nabla_{\mathbf{w}_t^{(\ell)}} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{y}}} \cdot \frac{\partial \hat{\mathbf{y}}}{\partial \boldsymbol{\xi}^{(N-1)}} \cdots \frac{\partial \boldsymbol{\xi}^{(\ell)}}{\partial \mathbf{w}_t^{(\ell)}}; \quad (21)$$

В современной литературе принята также более компактная форма записи уравнения (21):

$$\theta_{t+1} = \theta_t - \alpha \nabla_{\theta_t} \mathcal{L}(\theta_t). \quad (22)$$

В последние годы активно используются более современные методы для градиентного спуска. Один из наиболее эффективных методов оптимизации является алгоритм Adam [12], который является наиболее часто используемым методом в современных работах:

$$\begin{aligned} \mathbf{m}_0 &= \mathbf{0}, \quad \mathbf{v}_0 = \mathbf{0}; \\ \mathbf{m}_{t+1} &= \beta_1 \mathbf{m}_t + (1 - \beta_1) \nabla_{\theta_t} \mathcal{L}(\theta_t); \\ \mathbf{v}_{t+1} &= \beta_2 \mathbf{v}_t + (1 - \beta_2) [\nabla_{\theta_t} \mathcal{L}(\theta_t)]^2; \\ \hat{\mathbf{m}}_{t+1} &= \frac{\mathbf{m}_{t+1}}{1 - \beta_1^{t+1}}, \quad \hat{\mathbf{v}}_{t+1} = \frac{\mathbf{v}_{t+1}}{1 - \beta_2^{t+1}}; \\ \theta_{t+1} &= \theta_t - \alpha_t \frac{\hat{\mathbf{m}}_{t+1}}{\sqrt{\hat{\mathbf{v}}_{t+1} + \epsilon}}. \end{aligned} \quad (23)$$

Здесь $\mathbf{m}_t$ и $\mathbf{v}_t$ — оценки первого и второго моментов градиента, $\beta_1 \in (0.5, 0.99)$, $\beta_2 \in (0.8, 0.999)$ — коэффициенты затухания, $\epsilon \sim 10^{-8}$ — малая константа для численной устойчивости, $\hat{\mathbf{m}}_{t+1}$, $\hat{\mathbf{v}}_{t+1}$ — скорректированные на смещение оценки. В ряде работ, посвящённым вычислительным экспериментам [8], метод Adam в среднем показывает наилучшую сходимость и точность по сравнению с другими алгоритмами оптимизации.

2.2 Архитектура обратимых нейронных сетей

Одним из фундаментальных ограничений стандартных полносвязных нейронных сетей, описанных в подразделе 2.3, является отсутствие свойства биективности. Поиск обратного отображения для стандартной нейронной сети является нетривиальной задачей. Более того, если размерность входного пространства M не равна размерности выходного пространства D , то биекция в строгом математическом смысле невозможна. Для решения этой проблемы применяются архитектуры обратимых нейронных сетей (Invertible Neural Networks, INN) [9, 10].

Основная идея INN заключается в построении априори обратимого отображения $g : \mathcal{X} \rightarrow \mathcal{Y}$, для которого существует точное аналитическое выражение для обратного преобразования $f = g^{-1}$. В основе таких сетей лежат так называемые «слои склейки» (coupling layers). Пусть входной вектор разбит на две части $\mathbf{u} = [\mathbf{u}_1, \mathbf{u}_2]$. Прямое преобразование $\mathbf{v} = g(\mathbf{u})$ задается системой:

$$\mathbf{v}_1 = (\mathbf{u}_2 + \mathbf{t}_1(\mathbf{u}_1)) \otimes \exp(\mathbf{s}_1(\mathbf{u}_1)), \quad (24)$$

$$\mathbf{v}_2 = (\mathbf{u}_1 + \mathbf{t}_2(\mathbf{v}_1)) \otimes \exp(\mathbf{s}_2(\mathbf{v}_1)), \quad (25)$$

где оператор $\otimes$ обозначает поэлементное произведение, а $\mathbf{s}_1$, $\mathbf{t}_1$, $\mathbf{s}_2$, $\mathbf{t}_2$ — произвольные нейросетевые функции. Обратное преобразование в этом случае вычисляется тривиально:

$$\mathbf{u}_1 = (\mathbf{v}_2 \otimes \exp(-\mathbf{s}_2(\mathbf{v}_1))) - \mathbf{t}_2(\mathbf{v}_1), \quad (26)$$

$$\mathbf{u}_2 = (\mathbf{v}_1 \otimes \exp(-\mathbf{s}_1(\mathbf{u}_1))) - \mathbf{t}_1(\mathbf{u}_1). \quad (27)$$

Чередование таких слоев с перестановками элементов вектора позволяет строить глубокие обратимые архитектуры.

2.2.1 Решение проблемы несовпадения размерностей

Описанная выше архитектура работает только в случае, когда размерности пространств $\mathcal{X}$ и $\mathcal{Y}$ равны. Если же приходится иметь дело с отображением из пространства большей размерности $\mathcal{X}$ в пространство меньшей размерности $\mathcal{Y}$, то для сохранения биективности вводится латентное пространство $\mathcal{Z} \in \mathbb{R}^K$, где $K = \dim(\mathcal{X}) - \dim(\mathcal{Y})$. Предполагается, что латентное пространство имеет стандартное нормальное распределение:

$$\mathbf{Z} \sim p_{\mathbf{Z}}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}_K). \quad (28)$$

Таким образом, обучаемая модель реализует биективное отображение $f_{\theta} : \mathcal{X} \rightarrow [\mathcal{Y}, \mathcal{Z}]$.

2.2.2 Функция потерь и метод максимального правдоподобия

Согласно формуле замены переменной, плотность распределения входных данных $p_{\mathcal{X}}(\mathbf{x})$ связана с плотностью распределения выходных через якобиан прямого преобразования:

$$p_{\mathcal{X}}(\mathbf{x}) = p_{\mathcal{Y}, \mathcal{Z}}(\mathbf{y}, \mathbf{z}) \cdot \left| \det \left(\frac{\partial f_{\theta}}{\partial \mathbf{x}} \right) \right|, \quad (29)$$

где $\mathbf{y} = f_{\mathcal{Y}}(\mathbf{x}; \theta)$ и $\mathbf{z} = f_{\mathcal{Z}}(\mathbf{x}; \theta)$ — компоненты прямого преобразования. Переходя к задаче минимизации, получаем суммарный функционал потерь:

$$\mathcal{L}(\theta) = \lambda_1 \mathcal{L}_y(\theta) + \lambda_2 \mathcal{L}_z(\theta), \quad (30)$$

где:

1. $\mathcal{L}_y(\theta)$ отвечает за точность восстановления наблюдаемых данных:

$$\mathcal{L}_y(\theta) = \frac{1}{2} \|\mathbf{y}_{\text{true}} - \mathbf{y}_{\text{pred}}\|^2. \quad (31)$$

2. $\mathcal{L}_z(\theta)$ выводится из условия соответствия латентного вектора априорному распределению. Логарифм правдоподобия для латентной компоненты имеет вид:

$$l_z(\theta) = \ln p_{\mathcal{Z}}(\mathbf{z}) + \ln \left| \det \left(\frac{\partial f_{\theta}}{\partial \mathbf{x}} \right) \right| = -\frac{1}{2} \|\mathbf{z}\|^2 + \ln |J_x|, \quad (32)$$

где использовано $p_{\mathcal{Z}}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}_K)$. Поскольку максимизация правдоподобия эквивалентна минимизации отрицательного логарифма, получаем:

$$\mathcal{L}_z(\theta) = -l_z(\theta) = \frac{1}{2} \|\mathbf{z}\|^2 - \ln |J_x|. \quad (33)$$

2.2.3 Эффективное вычисление якобиана

Ключевым преимуществом используемой архитектуры является возможность точного и эффективного вычисления определителя матрицы Якоби $\mathbf{J} = \partial \mathbf{v} / \partial \mathbf{u}$. Преобразование (24)–(25) может быть представлено как композиция двух последовательных отображений f_1 и f_2 . На первом этапе вектор $\mathbf{u}_2$ масштабируется и сдвигается в зависимости от $\mathbf{u}_1$, что формирует блочно-треугольный якобиан $\mathbf{J}_1$ с диагональю $\text{diag}(\exp(\mathbf{s}_1(\mathbf{u}_1)))$. На втором этапе аналогичное преобразование применяется к $\mathbf{u}_1$ с использованием уже вычисленного промежуточного вектора, формируя блочно-треугольную структуру $\mathbf{J}_2$ с диагональю $\text{diag}(\exp(\mathbf{s}_2(\mathbf{v}_1)))$.

Определитель полной матрицы Якоби равен произведению определителей составляющих:

$$|J_x| = |\mathbf{J}_1| \cdot |\mathbf{J}_2| = \prod_i \exp(s_1(\mathbf{u}_1)_i) \cdot \prod_i \exp(s_2(\mathbf{v}_1)_i) = \exp\left(\sum_i s_1(\mathbf{u}_1)_i + \sum_i s_2(\mathbf{v}_1)_i\right). \quad (34)$$

Логарифм определителя, необходимый для вычисления слагаемого $\mathcal{L}_z(\theta)$, определяется как простая сумма выходов подсетей $\mathbf{s}_1$ и $\mathbf{s}_2$:

$$\ln |J_x| = \sum_i s_1(\mathbf{u}_1)_i + \sum_i s_2(\mathbf{v}_1)_i. \quad (35)$$

Таким образом, вычисление якобиана имеет линейную сложность $O(d)$ и не требует формирования или обращения полных матриц частных производных. Итоговая функция потерь принимает вид:

$$\mathcal{L}(\theta) = \lambda_1 \|\mathbf{y}_{\text{true}} - \mathbf{y}_{\text{pred}}\|^2 + \lambda_2 \left(\frac{1}{2} \|\mathbf{z}\|^2 - \ln |J_x| \right), \quad (36)$$

что критически важно для эффективного обучения глубоких обратимых сетей методом стохастического градиентного спуска.

2.2.4 Построение многослойной обратимой архитектуры

Одиночный обратимый слой преобразует лишь часть входного вектора, оставляя другую часть неизменной на данном шаге. Для повышения обобщающих способностей модели требуется использовать многослойную архитектуру. Полное преобразование $f_\theta: \mathbf{X} \rightarrow [\mathbf{R}, \mathbf{Z}]$ представляется в виде композиции из L обратимых блоков:

$$f_\theta = f^{(L)} \circ P_{L-1} \circ f^{(L-1)} \circ \dots \circ P_1 \circ f^{(1)}, \quad (37)$$

где $f^{(\ell)}$ — ℓ -й обратимый слой вида (24)–(25), а P_ℓ — оператор перестановки, применяемый между слоями. Перестановка гарантирует, что компоненты, зафиксированные на предыдущем шаге, будут трансформированы на последующих.

В каждом слое функции масштабирования $\mathbf{s}_{1,2}^{(\ell)}$ и сдвига $\mathbf{t}_{1,2}^{(\ell)}$ параметризуются многослойными персептронами. Поскольку выходы $\mathbf{s}_{1,2}^{(\ell)}$ используются в экспоненте, на функции $\mathbf{s}_{1,2}^{(\ell)}$ накладывается ограничение $\tanh$ чтобы избежать взрывного роста или исчезновения градиентов при вычислении $\exp(\mathbf{s}_{1,2}^{(\ell)})$.

Обратимость всей композиции сохраняется автоматически: обратное преобразование вычисляется последовательным применением обратных шагов в обратном порядке:

$$f_\theta^{-1} = (f^{(1)})^{-1} \circ P_1^{-1} \circ \dots \circ P_{L-1}^{-1} \circ (f^{(L)})^{-1}. \quad (38)$$

Логарифм определителя Якобиана полной сети равен сумме логарифмов определителей отдельных слоёв:

$$\ln \left| \det \frac{\partial f_\theta}{\partial \mathbf{X}} \right| = \sum_{\ell=1}^L \ln \left| \det \frac{\partial f^{(\ell)}}{\partial \mathbf{u}^{(\ell-1)}} \right|, \quad (39)$$

что сохраняет линейную вычислительную сложность $O(L \cdot d)$ и позволяет эффективно оптимизировать функционал (30) методами стохастического градиентного спуска без формирования полных матриц производных.

Глубина сети L и ширина подсетей выбираются эмпирически.

2.3 Подготовка данных

Для обучения нейросетевого аппроксиматора обратной задачи была сформирована выборка из пар $(\mathbf{X}, \mathbf{R})$, где $\mathbf{X} = (E_1, \dots, E_4, \nu_1, \dots, \nu_4)$ — вектор упругих параметров полосы, $\mathbf{R} = [r_k]_{k=1}^8$ — сеточная функция нормализованных контактных усилий, вычисленная алгоритмом [1].

Разбиение выборки

Общий объём сгенерированной выборки составил 150 826 примеров. Данные были разделены на три непересекающихся подмножества:

- **Обучающая выборка** (120 826 примеров, $\approx 80\%$) — используется для настройки весовых коэффициентов нейронной сети в процессе минимизации функционала потерь (18);
- **Валидационная выборка** (15 000 примеров, $\approx 10\%$) — применяется для контроля переобучения, подбора гиперпараметров модели и ранней остановки обучения;
- **Тестовая выборка** (15 000 примеров, $\approx 10\%$) — служит для финальной оценки обобщающей способности обученной модели на данных, не участвовавших в процессе обучения.

Такое разбиение позволяет объективно оценить качество модели и избежать ситуации, когда сеть «запоминает» обучающие примеры, но плохо работает на новых данных [4, 5].

Подготовка данных

Перед подачей в нейронную сеть входные и целевые признаки подвергаются стандартизации с использованием Z -нормализации:

$$x' = \frac{x - \mu}{\sigma}, \quad (40)$$

где μ и σ — выборочное среднее и стандартное отклонение признака x , вычисленные по обучающей выборке.

Параметры μ и σ , вычисленные на обучающей выборке, сохраняются и применяются для масштабирования валидационной и тестовой выборок, что обеспечивает корректность оценки качества модели.

3 Численные решения.

3.1 Решение прямой задачи с помощью

Мотивация

В случае существования биективного отображения, точность решения обратной задачи идентификации упругих параметров полосы должна напрямую зависеть от точности аппроксимации прямого отображения $\mathcal{F}_{\text{direct}}: \mathbf{X} \mapsto \mathbf{R}$. Чем точнее нейросетевая модель воспроизводит зависимость между входными параметрами материала $\mathbf{X} = (E_1, \dots, E_4, \nu_1, \dots, \nu_4)$ и выходными сеточными функциями нормализованных контактных усилий $\mathbf{R} = [r_k]_{k=1}^8$, тем более устойчивым и точным будет восстановление параметров в обратной задаче.

3.1.1 Архитектура модели

Для аппроксимации отображения $\mathcal{F}_{\text{direct}}$ используется полносвязная нейронная сеть с функциями активации. Архитектура нейронной сети представлена в таб. 1.




Рис. 3: Динамика изменения функции потерь при обучении нейронной сети на первых 150 эпохах

Модель реализована на базе фреймворка PyTorch. Оптимизация параметров сети осуществлялась методом Adam (23) с начальным шагом обучения $\alpha = 10^{-3}$, который постепенно уменьшался до $\alpha = 10^{-5}$.

3.1.2 Результаты обучения

Обучение проводилось на протяжении 300 эпох, в результате были достигнуты результаты, представленные в таблице 2:

Таблица 2: Метрики качества аппроксимации прямой задачи на тестовой выборке

Метрика	Значение	Интерпретация
R^2	1.0000	Коэффициент детерминации
$L1\text{-norm}$	1.38×10^{-4}	Нормированная абсолютная погрешность
$L2\text{-norm}$	1.98×10^{-4}	Нормированная квадратичная погрешность

Значение $R^2 = 1.0000$ (с точностью до машинного округления) свидетельствует о практически идеальном воспроизведении целевой переменной $\mathbf{R}$ по входным параметрам $\mathbf{X}$. Столь высокая точность обусловлена детерминированным характером прямой задачи и отсутствием шумов в данных, полученных численным алгоритмом [1].

На рис. 3 представлена зависимость значения функции потерь от номера эпохи обучения.

Промежуточный вывод

Построенная нейросетевая модель обеспечивает высокоточную аппроксимацию прямого отображения $\mathcal{F}_{\text{direct}}$ с погрешностью, близкой к машинному нулю. Это создаёт надёжную

Слой	Размерность	Активация
Вход	8	—
Linear	$8 \rightarrow 256$	GELU
Linear	$256 \rightarrow 256$	GELU
Linear	$256 \rightarrow 64$	GELU
Linear	$64 \rightarrow 64$	GELU
Linear	$64 \rightarrow 8$	—
Выход	8	—

Таблица 1: Архитектура подсетей

основу для решения обратной задачи: наличие прямого отображения даёт надежду на существование хорошего обратного отображения в случае биективности решения.

3.2 Обратимые нейронные сети без латентного пространства

3.2.1 Архитектура

Был рассмотрен случай, где размерности входного и выходного пространств совпадают, и отображение $f_\theta: \mathbf{X} \rightarrow \mathbf{R}$ реализуется непосредственно через композицию обратимых блоков. Была предложена архитектура, в которой функции $\mathbf{s}_{1,2}^\ell(\cdot)$ и $\mathbf{t}_{1,2}^\ell(\cdot)$ параметризуются многослойными персептронами с архитектурами, представленными в таблице 3. Ограничение выхода $\mathbf{s}_{1,2}^\ell(\cdot)$ играет критическую роль для численной устойчивости обратимой архитектуры. Поскольку масштабирование в прямом и обратном проходах осуществляется через $\exp(\mathbf{s}_{1,2}^\ell)$ и $\exp(-\mathbf{s}_{1,2}^\ell)$, соответственно, неограниченные значения $\mathbf{s}_{1,2}^\ell$ могут приводить к взрыву или исчезновению градиентов. Диапазон $[-3, 3]$ обеспечивает $\exp(\mathbf{s}_{1,2}^\ell) \in [e^{-3}, e^3] \approx [0.05, 20.08]$.

Для улучшения репрезентативных свойств, была предложена многослойная обратимая нейронная сеть с числом слоев $L = 4$, в соответствии с выражением (37). На каждом из слоев, персептроны $\mathbf{s}_{1,2}^\ell$ и $\mathbf{t}_{1,2}^\ell$ удовлетворяют архитектуре 3. Процесс обучения (на первых 200 эпохах) представлен на рисунке 4.




Рис. 4: Динамика изменения функции потерь при обучении обратимой нейронной сети без латентного пространства на первых 200 эпохах

Слой	Размерность	Ограничение
Подсети $\mathbf{s}_{1,2}(\cdot)$		
Вход	4	—
Linear	$4 \rightarrow 16$	GELU
Linear	$16 \rightarrow 16$	GELU
Выходной	$16 \rightarrow 4$	$3 \cdot \tanh(\cdot)$
Подсети $\mathbf{t}_{1,2}(\cdot)$		
Вход	4	—
Linear	$4 \rightarrow 32$	GELU
Linear	$32 \rightarrow 16$	GELU
Выходной	$16 \rightarrow 4$	Линейная

Таблица 3: Архитектура подсетей

3.2.2 Результаты обучения

Модель реализована на базе фреймворка PyTorch. Оптимизация параметров сети осуществлялась методом Adam (23) с начальным шагом обучения $\alpha = 10^{-3}$, который постепенно уменьшался до $\alpha = 10^{-7}$ за 2000 эпох обучения. В результате достигнуты результаты, представленные в таблице 4:

Метрика	Значение	Интерпретация
Прямой проход		
R^2	0.99	Коэффициент детерминации
$L1\text{-norm}$	7.83×10^{-3}	Нормированная абсолютная погрешность
$L2\text{-norm}$	9.69×10^{-3}	Нормированная квадратичная погрешность
Обратный проход		
R^2	0.45	Коэффициент детерминации
$L1\text{-norm}$	1.44×10^{-1}	Нормированная абсолютная погрешность
$L2\text{-norm}$	1.90×10^{-1}	Нормированная квадратичная погрешность

Таблица 4: Метрики качества аппроксимации прямой задачи на тестовой выборке

Промежуточный вывод

Одной из причин слабых обобщающих способностей выбранной модели может являться шум в данных. Удаление данного шума должно увеличить репрезентативные способности нейронной сети, однако, это вынуждает понижать размерность векторов $\mathbf{R}$, и, соответственно, делает невозможным использование обратимых нейронных сетей без латентного пространства.

3.3 Обратимые нейронные сети с латентным пространством

3.3.1 Метод главных компонент

Для улучшения обобщающих способностей модели, предложенной в главе 3.2 предлагается удалить шум из $\mathbf{R}$. В качестве решения данной проблемы может быть рассмотрен алгоритм сжатия данных, который называется методом главных компонент (Principal component analysis, PCA [4]).

Данный метод основан на, основанный на сингулярном разложении матрицы (Singular Value Decomposition, SVD [4]): любая прямоугольная матрица $\mathbf{A}$ размерности $m \times n$, может быть представлена, как

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^T, \quad (41)$$

где $\mathbf{U}$ и $\mathbf{V}$ — унитарные матрицы, а $\mathbf{\Lambda}$ — диагональная. Известно [4], что:

- диагональные элементы матрицы $\mathbf{\Lambda}$ совпадают с $\sigma_1, \dots, \sigma_m$, сингулярными значениями матрицы $\mathbf{A}$ (т.е. арифметическими значениями квадратных корней из собственных значений матриц $\mathbf{A}\mathbf{A}^T$);
- столбцы матриц $\mathbf{U}$ и $\mathbf{V}^T$ совпадают с собственными векторами матриц $\mathbf{A}\mathbf{A}^T$ и $\mathbf{A}^T\mathbf{A}$, соответственно, и образуют ортогональные базисы.

Для определённости будем считать, что $\sigma_1, \dots, \sigma_m$ расставлены на диагонали в порядке убывания. Пусть $\mathbf{\Lambda}_d$ — главный минор d -ого порядка матрицы $\mathbf{\Lambda}$. Если начиная с какого-то σ_d сингулярные значения становятся достаточно малы, то $\mathbf{A} \cong \mathbf{U}\mathbf{\Lambda}_d\mathbf{V}$. Тогда можно отобразить матрицу $\mathbf{A}$ на пространство размерности d с базисными векторами — столбцами главного минора d -ого порядка $\mathbf{V}_d$ матрицы $\mathbf{V}$, получается матрица $\mathbf{Z}$:

$$\mathbf{Z} = \mathbf{A}\mathbf{V}_d. \quad (42)$$

Тогда оператор $F(\mathbf{x})$, сжимающий данные, и обратный ему $G(\mathbf{z})$ описываются как:

$$F(\mathbf{x}) = V_d^T \mathbf{x}, \quad (43)$$

$$G(\mathbf{z}) = V_d \mathbf{z}. \quad (44)$$

Таким образом возможно уменьшить размерность данных, оставив только наиболее значимые компоненты и избавившись от шума в данных. В данной работе удалось преобразовать $\mathbf{R} \in \mathbb{R}^8$ в $\hat{\mathbf{R}} \in \mathbb{R}^4$ потеряв менее 1% точности при восстановлении данных.

3.3.2 Архитектура

Также, как и в предыдущем случае, отображение $f_\theta: \mathbf{X} \rightarrow [\hat{\mathbf{R}}, \mathbf{Z}]$, где $\hat{\mathbf{R}}$ получено из $\mathbf{R}$ при помощи преобразования (43), а $\mathbf{Z} \in \mathcal{N}(0, 1)$, как описано в разделе 2.2.1, реализуется через композицию обратимых блоков. Функции $\mathbf{s}_{1,2}^\ell(\cdot)$ и $\mathbf{t}_{1,2}^\ell(\cdot)$ параметризуются многослойными перцептронами с архитектурами, представленными в таблице 5. Отметим, что на выходы $\mathbf{s}_{1,2}^\ell(\cdot)$ накладываются такие же ограничения, как и в случае без латентного пространства.

Получившаяся многослойная обратимая нейронная сеть с числом слоев $L = 6$ имеет на каждом из уровней перцептроны $\mathbf{s}_{1,2}^\ell$ и $\mathbf{t}_{1,2}^\ell$, которые удовлетворяют архитектурам, предложенным в таблице 5. Процесс обучения представлен на рисунке 5.




Рис. 5: Динамика изменения функции потерь при обучении обратимой нейронной сети с латентным пространством

Слой	Размерность	Ограничение
Подсети $\mathbf{s}_{1,2}(\cdot)$		
Вход	4	—
Linear	$4 \rightarrow 64$	GELU
Linear	$64 \rightarrow 32$	GELU
Выходной	$32 \rightarrow 4$	$3 \cdot \tanh(\cdot)$
Подсети $\mathbf{t}_{1,2}(\cdot)$		
Вход	4	—
Linear	$4 \rightarrow 128$	GELU
Linear	$128 \rightarrow 64$	GELU
Linear	$64 \rightarrow 32$	GELU
Выходной	$32 \rightarrow 4$	Линейная

Таблица 5: Архитектура подсетей

3.3.3 Результаты обучения

Модель реализована на базе фреймворка PyTorch. Оптимизация параметров сети осуществлялась методом Adam (23) с начальным шагом обучения $\alpha = 10^{-3}$, который постепенно уменьшался до $\alpha = 10^{-7}$. После 600 эпох обучения на тестовой выборке были достигнуты результаты, показанные в таблице 6.

Предварительный вывод

Данная архитектура показала прирост качества относительно предыдущей версией. Удаление шума при помощи метода главных компонент помогло значительно улучшить обобщающие способности нейронной сети.

Таблица 6: Метрики качества аппроксимации прямой задачи на тестовой выборке

Метрика	Значение	Интерпретация
Прямой проход		
R^2	0.99	Коэффициент детерминации
$L1\text{-norm}$	3.83×10^{-3}	Нормированная абсолютная погрешность
$L2\text{-norm}$	4.69×10^{-3}	Нормированная квадратичная погрешность
Обратный проход		
R^2	0.67	Коэффициент детерминации
$L1\text{-norm}$	7.34×10^{-2}	Нормированная абсолютная погрешность
$L2\text{-norm}$	9.91×10^{-2}	Нормированная квадратичная погрешность

Вывод

В данной работе исследована возможность применения обратимых нейронных сетей для решения обратной задачи идентификации упругих параметров четырёхслойной упругой полосы по данным коллективного индентирования. На основе численных экспериментов получены следующие основные результаты:

1. **Аппроксимация прямой задачи.** Многослойный персептрон обеспечивает высокоточную аппроксимацию отображения $\mathcal{F}_{\text{direct}} : \mathbf{X} \mapsto \mathbf{R}$.
2. **Обратимые сети без латентного пространства.** Архитектура INN с биективным отображением $\mathbf{X} \rightarrow \mathbf{R}$ продемонстрировала удовлетворительную точность в прямом проходе, однако качество восстановления параметров в обратном проходе оказалось ограниченным. Основной причиной является мультиколлинеарность компонент вектора $\mathbf{R}$ и чувствительность архитектуры к шуму в данных.
3. **Обратимые сети с латентным пространством.** Применение метода главных компонент позволило снизить размерность выходного пространства с 8 до 4 компонент при потере менее 1% информации. Архитектура INN с латентным пространством показала улучшение качества обратного восстановления, что подтверждает эффективность удаления шума в данных и добавления латентных переменных для компенсации несоответствия размерностей входного и выходного пространств.

Заключение. Разработанный подход на основе обратимых нейронных сетей с латентным пространством демонстрирует потенциал для решения обратных задач механики контактного взаимодействия.

Список литературы

- [1] *Бобылев А.А.* Задача коллективного индентирования упругой полуплоскости системой жестких штампов, упруго связанных с общей платформой // Прикл. матем. и механика. 2025. Т. 89. № 2. С. 280–294.
- [2] *Бобылев А.А.* Задача одностороннего дискретного контакта для функционально-градиентной упругой полосы // Вест. Моск. ун-та. Сер. 1. Матем. Механ. 2024. № 2. С. 58–69.
- [3] *Хайкин С.* Нейронные сети: полный курс. М.: Вильямс, 2002. С. 500–540.
- [4] *Cherkassky V., Mulier F.* Learning from Data: Concepts, Theory, and Methods. 2nd ed. John Wiley & Sons, 2007. P. 249–284.
- [5] *Chollet F.* Deep Learning with Python. СПб.: Питер, 2018. С. 100–400.
- [6] *Yagava G., Onishi A.* Computational Mechanics with Deep Learning. Lecture Notes on Numerical Methods in Engineering and Sciences., 2022. P. 10–150.
- [7] *Helton J.C., Davis F.J.* Latin Hypercube Sampling and the Propagation of Uncertainty in Analyses of Complex Systems. // Sandia Report, 2022.
- [8] *Choi D., Shallue C.J., Nado Z., Lee J., Maddison C.J., Dahl G.E.* On Empirical Comparisons of Optimizers for Deep Learning., 2020.
- [9] *Ardizzone L., Lüth C., Kruse J., Rother C., Köthe U.* Guided Image Generation with Conditional Invertible Neural Networks. // Visual Learning Lab Heidelberg, 2019.
- [10] *Ardizzone L., Kruse J., Wirkert S., Rahner D., Pellegrini E.W., Klessen R.S., Maier-Hein L., Rother C., Köthe U.* Analyzing Inverse Problems with Invertible Neural Networks. // Proc. of the 7th Int. Conf. on Learning Representations (ICLR 2019), 2019.
- [11] *Kruse J., Ardizzone L., Rother C., Köthe U.* Benchmarking Invertible Architectures on Inverse Problems., 2021.
- [12] *Diederik P. Kingma, Jimmy Lei Ba.* Adam: a method for stochastic optimization., 2015