

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ УЧРЕЖДЕНИЕ  
ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ  
УНИВЕРСИТЕТ имени М.В. ЛОМОНОСОВА»

МЕХАНИКО-МАТЕМАТИЧЕСКИЙ ФАКУЛТЕТ

КАФЕДРА ТЕОРИИ УПРУГОСТИ

КУРСОВАЯ РАБОТА

*специалиста*

Применение обратимых нейронных сетей для идентификации параметров  
многослойной упругой полосы

Application of invertible neural networks to identify the parameters of  
a multilayer elastic strip

Выполнил студент  
525 группы  
Леонов Иван Алексеевич

\_\_\_\_\_  
подпись студента.

Научный руководитель:  
к.ф.-м.н., доцент  
Бобылев Александр Александрович

\_\_\_\_\_  
подпись научного руководителя.

Москва 2026

# Содержание

|          |                                                                         |           |
|----------|-------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Постановка прямой задачи</b>                                         | <b>3</b>  |
| 1.1      | Сеточные функции контактных усилий и постановка обратной задачи . . . . | 5         |
| 1.2      | Параметризация упругих свойств функционально-градиентной полосы . . .   | 5         |
| 1.3      | Формулировка обратной задачи . . . . .                                  | 6         |
| <b>2</b> | <b>Нейросетевой аппроксиматор</b>                                       | <b>6</b>  |
| 2.1      | Алгоритм работы . . . . .                                               | 6         |
| 2.2      | Архитектура обратимых нейронных сетей . . . . .                         | 7         |
| 2.2.1    | Решение проблемы несовпадения размерностей . . . . .                    | 8         |
| 2.2.2    | Функция потерь и метод максимального правдоподобия . . . . .            | 8         |
| 2.2.3    | Эффективное вычисление якобиана . . . . .                               | 8         |
| 2.2.4    | Построение многослойной обратимой архитектуры . . . . .                 | 9         |
| 2.3      | Подготовка данных . . . . .                                             | 10        |
| <b>3</b> | <b>Численные решения.</b>                                               | <b>10</b> |
| 3.1      | Решение прямой задачи с помощью . . . . .                               | 10        |
| 3.1.1    | Архитектура модели . . . . .                                            | 11        |
| 3.1.2    | Результаты обучения . . . . .                                           | 11        |
| 3.2      | Обратимые нейронные сети без латентного пространства . . . . .          | 12        |
| 3.2.1    | Архитектура . . . . .                                                   | 12        |
| 3.2.2    | Результаты обучения . . . . .                                           | 12        |
| 3.3      | Обратимые нейронные сети с латентным пространством . . . . .            | 13        |
| 3.3.1    | Метод главных компонент . . . . .                                       | 13        |
| 3.3.2    | Архитектура . . . . .                                                   | 14        |
| 3.3.3    | Результаты обучения . . . . .                                           | 14        |

# Введение

Задача идентификации параметров многослойной упругой полосы по данным индентирования представляет собой актуальную проблему механики деформируемого твёрдого тела. Многослойные структуры, характеризующиеся ступенчатым изменением упругих модулей и толщин отдельных слоёв, широко применяются в современных инженерных конструкциях, однако их дискретная неоднородность существенно усложняет восстановление механических и геометрических характеристик по экспериментальным или численным данным контактного взаимодействия. Прямая задача коллективного индентирования, описывающая связь между набором параметров слоёв и нормализованными контактными усилиями, решается эффективно, тогда как обратная задача является некорректно поставленной и требует применения специализированных подходов.

В последнее время для решения обратных задач всё шире применяются нейросетевые модели, обладающие способностью аппроксимировать сложные нелинейные зависимости. Тем не менее, традиционные архитектуры не обеспечивают свойство обратимости и взаимно-однозначного соответствия. Альтернативой выступают обратимые нейронные сети (Invertible Neural Networks, INN), которые реализуют биективное отображение между пространством параметров слоёв и пространством наблюдаемых контактных данных. Такие сети допускают точное аналитическое обращение, что может быть критически важно для устойчивого решения обратных задач идентификации.

Основное внимание в работе уделено численной реализации алгоритма решения задачи идентификации параметров четырехслойной упругой полосы и сравнению различных подходов: классического многослойного персептрона для прямой задачи, обратимых сетей без латентного пространства и архитектур с введением латентных переменных для компенсации несовпадения размерностей пространства параметров слоёв и размерности наблюдаемых данных.

## 1 Постановка прямой задачи

Пусть невесомая многослойная упругая полоса в прямоугольной декартовой системе координат  $Ox_1x_2$  занимает область

$$\Omega = \{\mathbf{x} = (x_1, x_2) \in \mathbb{R}^2 : 0 \leq x_2 \leq h, |x_1| \leq \infty\} \quad (1)$$

и состоит из  $N$  упругих слоёв  $\Omega_n$ , границы раздела которых параллельны оси  $Ox_1$ . Слои пронумерованы от 1 до  $N$  в порядке возрастания координаты  $x_2$ . Слой  $\Omega_n$ ,  $n = \overline{1, N}$  имеет толщину  $h_n$  и является однородным и изотропным со значениями модуля Юнга и коэффициента Пуассона  $E_n$  и  $\nu_n$  (рис. (2)).

Под  $u_i^{(n)}(\mathbf{x})$ ,  $\sigma_{ij}^{(n)}(\mathbf{x})$ ,  $i, j = 1, 2$  будем понимать соответственно компоненты вектора перемещений и тензора напряжений в точке  $\mathbf{x} \in \Omega_n$ .

Предполагается, что упругая полоса находится в условиях плоской деформации, деформации малы, а массовые силы и напряжения в недеформированном состоянии отсутствуют.

Границу полосы  $x_2 \equiv 0$  обозначим через  $\Gamma_0$ , границу  $x_2 \equiv h_1 + \dots + h_n$  раздела слоёв  $\Omega_n$  и  $\Omega_{n+1}$  — через  $\Gamma_n$ ,  $n = \overline{1, N-1}$ , а границу полосы  $x_2 \equiv h$  — через  $\Gamma_N$ . Напряжённо-деформированное состояние слоев  $\Omega_n$ ,  $n = \overline{1, N-1}$  описывается системой уравнений:

$$\boldsymbol{\varepsilon} = \text{def } \mathbf{u}, \quad \boldsymbol{\sigma} = \mathbf{S} : \boldsymbol{\varepsilon}, \quad \text{div } \boldsymbol{\sigma} = \mathbf{0} \quad \text{в } \Omega_n, \quad (2)$$

где  $\text{def} = \frac{1}{2}(\text{grad} + \text{grad}^T)$ .




Рис. 1: Система штампов




Рис. 2: Схема четырехслойной полосы

Вдоль границы  $\Gamma_0$  полоса соединена с недеформируемым основанием. В случае полного сцепления граничные условия имеют вид:

$$u_1 = u_2 = 0 \quad \text{на } \Gamma_0. \quad (3)$$

На границах раздела слоёв также задаются условия полного сцепления:

$$u_1^{(n)} = u_1^{(n+1)}, \quad u_2^{(n)} = u_2^{(n+1)}, \quad \sigma_{12}^{(n)} = \sigma_{12}^{(n+1)}, \quad \sigma_{22}^{(n)} = \sigma_{22}^{(n+1)} \quad \text{на } \Gamma_n, \quad n = \overline{1, N-1}. \quad (4)$$

Рассматривается задача о вдавливании системы гладких жёстких штампов  $\Pi_k$ ,  $k = \overline{1, K}$ , упруго связанных с общей жёсткой платформой  $\Pi_0$ , в полосу (рис. (1).) Требуется определить поля напряжений в упругом теле при заданных геометрических параметрах системы, механических характеристиках полосы и внешних нагрузках

Штампы  $\Pi_k$  соединены с платформой  $\Pi_0$  линейными упругими пружинами  $\Lambda_k$  с коэффициентами податливости  $c_k > 0$ . Штамп  $\Pi_k$  может поступательно перемещаться без трения вдоль прямолинейных направляющих платформы, параллельных оси  $Ox_2$  в исходном состоянии. Относительное перемещение штампа  $\Pi_k$  вдоль направляющих платформы  $\Pi_0$  обозначается  $\delta_k$ ; положительные значения  $\delta_k$  соответствуют сжатию пружины.

Положение платформы  $\Pi_0$  как жёсткого целого определяется вектором перемещений  $\delta^0 = (\delta_1^0, \delta_2^0)$  и углом поворота  $\varphi_3^0$ . Перемещения платформы и штампов, а также угол поворота платформы предполагаются малыми.

Часть границы  $\Gamma$ , по которой возможен контакт полосы со штампами, обозначается  $\Gamma^p$ . Предполагается, что  $\Gamma^p$  является конечной односвязной областью и может быть представлена в виде объединения непересекающихся подобластей  $\Gamma_k$ , соответствующих основаниям отдельных штампов:

$$\Gamma^p = \bigcup_{k=1}^K \Gamma_k, \quad \Gamma_k \cap \Gamma_j = \emptyset \quad (k \neq j). \quad (5)$$

Введём на  $\Gamma^p$ :

$$\delta(x_1) = \sum_{k=1}^K \delta_k \chi_k(x_1), \quad (6)$$

где  $\chi_k(x_1)$  — характеристическая функция области  $\Gamma_k$ .

Линеаризованные условия одностороннего гладкого контакта имеют вид:

$$\begin{aligned} u_2 &\leq \Phi + \delta_2^0 + \delta - (x_1 - x_1^c) \varphi_3^0, \\ \sigma_{22} &\leq 0, \quad \sigma_{12} = 0, \\ \sigma_{22} [u_2 - \Phi - \delta_2^0 - \delta + (x_1 - c_1) \varphi_3^0] &= 0 \end{aligned} \quad (7)$$

на  $\Gamma^p$ , где  $x_1^c$  — координата центра приведения платформы.

Остальная часть границы свободна от внешних нагрузок:

$$\sigma_{21} = \sigma_{22} = 0 \quad \text{на } \Gamma \setminus \Gamma^p. \quad (8)$$

Уравнения равновесия жёстких штампов  $\Pi_k$  имеют вид

$$c_k \int_{\Gamma_k} \sigma_{22} d\Gamma = -\delta_k, \quad k = \overline{1, K}. \quad (9)$$

Уравнения равновесия жёсткой платформы  $\Pi_0$  имеют вид:

$$\int_{\Gamma^p} \sigma_{22} d\Gamma = F_2, \quad \int_{\Gamma^p} (x_1 - x_1^c) \sigma_{22} d\Gamma = M_3, \quad (10)$$

где  $F_2 < 0$  — заданная нормальная компонента главного вектора внешних сил,  $M_3$  — заданный главный момент относительно центра приведения.

Для выделения класса единственности решения в рассматриваемой контактной задаче используется условие конечности потенциальной энергии деформации многослойной упругой полосы:

$$\int_{\Omega} \sigma : \varepsilon d\Omega. \quad (11)$$

## 1.1 Сеточные функции контактных усилий и постановка обратной задачи

Для формулировки обратной задачи введём сеточную функцию нормализованных контактных усилий  $\mathbf{R} = [r_k]_{k=1}^K$ , определяемую как

$$r_k = \frac{1}{|F_2|} \int_{\Gamma_k} p(x_1) d\Gamma, \quad k = \overline{1, K}, \quad (12)$$

где  $p(x_1) = -\sigma_{22}(x_1) \geq 0$  — распределение контактного давления на  $\Gamma^p$ ,  $F_2 < 0$  — заданная нормальная компонента главного вектора внешних сил. Компонента  $r_k$  характеризует долю суммарного контактного усилия, приходящуюся на область  $\Gamma_k$ , соответствующую штампу  $\Pi_k$ . По определению выполняется условие нормировки  $\sum_{k=1}^K r_k = 1$ .

Значения сеточной функции  $\mathbf{R}$  вычисляются путём численного решения прямой задачи коллективного индентирования с использованием алгоритма, разработанного в работе [1]. В работе будут рассматриваться семейства штампов с  $K = 8$ .

## 1.2 Параметризация упругих свойств функционально-градиентной полосы

Для описания неоднородных упругих свойств полосы используются безразмерные функции модуля Юнга  $E(x_2)$  и коэффициента Пуассона  $\nu(x_2)$ , где

$$E(x_2) = \frac{\tilde{E}(x_2)}{E^*}, \quad E^* = 10^5 \text{ МПа}, \quad (13)$$

$\tilde{E}(x_2)$  — размерный модуль Юнга,  $E^*$  — характерный масштаб для обезразмеривания. Будут рассматриваться задачи с параметрами из заданных диапазонов:  $E \in [0.2, 3]$ ,  $\nu \in [0.1, 0.45]$ .

Рассматриваются четырёхслойные полосы (рис. (2)), ввиду чего распределения  $E(x_2)$  и  $\nu(x_2)$  полностью определяются вектором

$$\mathbf{X} = (E_1, E_2, E_3, E_4, \nu_1, \nu_2, \nu_3, \nu_4) \in \mathbb{R}^8. \quad (14)$$

### 1.3 Формулировка обратной задачи

Прямая задача задаёт отображение

$$\mathcal{F}_{\text{direct}} : \mathbf{X} \mapsto \mathbf{R}, \quad (15)$$

сопоставляющее набор упругих параметров  $\mathbf{X}$  сеточной функции нормализованных контактных усилий  $\mathbf{R}$ .

Обратная задача: по измеренной при помощи алгоритма [1] сеточной функции  $\mathbf{R}$  восстановить вектор параметров  $\mathbf{X}$ . Решение задачи будет осуществляться с использованием нейросетевого аппроксиматора, обученного на выборке пар  $(\mathbf{X}, \mathbf{R})$ , полученных в результате многократного решения прямой задачи алгоритмом [1].

Для формирования обучающей выборки параметров  $\mathbf{X}$  используется метод латинского гиперкуба (Latin Hypercube Sampling, LHS) [7], обеспечивающий равномерное покрытие допустимой области параметров.

## 2 Нейросетевой аппроксиматор

### 2.1 Алгоритм работы

Рассмотрим структуру классической многослойной нейронной сети или многослойного персептрона. Пусть задана выборка  $\mathbf{X} = \{\mathbf{x}_i \in \mathbb{R}^d \mid i = 1, \dots, M\}$  и соответствующие целевые значения  $\mathbf{Y} = \{\mathbf{y}_i \in \mathbb{R}^k \mid i = 1, \dots, M\}$ . В качестве модели численного решения задачи строится оператор  $\mathcal{F}_\theta : \mathbb{R}^d \rightarrow \mathbb{R}^k$ , реализуемый многослойным персептроном:

$$\begin{aligned} \boldsymbol{\xi}^{(0)} &= \mathbf{x}, \quad \mathbf{x} \in \mathbf{X}; \\ \boldsymbol{\xi}^{(\ell)} &= \phi^{(\ell)}(\mathbf{W}^{(\ell)} \boldsymbol{\xi}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad \ell = 1, \dots, N-1; \\ \hat{\mathbf{y}} &= \mathcal{F}_\theta(\mathbf{x}) = \phi^{(N)}(\mathbf{W}^{(N)} \boldsymbol{\xi}^{(N-1)} + \mathbf{b}^{(N)}), \end{aligned} \quad (16)$$

где  $N$  — количество слоёв сети (задаётся априори),  $\phi^{(\ell)}$  — известные аналитически функции активации,  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}}$  и  $\mathbf{b}^{(\ell)} \in \mathbb{R}^{n_\ell}$  — матрицы весов и векторы смещений соответственно. Совокупность всех обучаемых параметров обозначается  $\theta = \{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_{\ell=1}^N$ , т.о. получаем выражение  $\hat{\mathbf{y}} = \mathcal{F}_\theta(\mathbf{x})$ .

Задача обучения сводится к минимизации функционала потерь  $\mathcal{L}$  на обучающей выборке:

$$\theta^* = \arg \min_{\theta} \frac{1}{M} \sum_{i=1}^M \mathcal{L}(\mathcal{F}_\theta(\mathbf{x}_i), \mathbf{y}_i). \quad (17)$$

В данной работе в качестве  $\mathcal{L}$  используется среднеквадратичная ошибка:

$$\mathcal{L}(\hat{\mathbf{y}}_i, \mathbf{y}_i) = \frac{1}{k} \sum_{j=1}^k (y_{ij} - \hat{y}_{ij})^2. \quad (18)$$

Оптимизация параметров осуществляется методом стохастического градиентного спуска или его модификациями. На каждом шаге  $t$  параметры обновляются по правилу:

$$\mathbf{W}_{t+1}^{(\ell)} = \mathbf{W}_t^{(\ell)} - \alpha \nabla_{\mathbf{W}_t^{(\ell)}} \mathcal{L}, \quad (19)$$

$$\mathbf{b}_{t+1}^{(\ell)} = \mathbf{b}_t^{(\ell)} - \alpha \nabla_{\mathbf{b}_t^{(\ell)}} \mathcal{L}, \quad (20)$$

где  $\alpha > 0$  — шаг обучения,  $t$  — номер итерации. Градиенты вычисляются с помощью алгоритма обратного распространения ошибки:

$$\nabla_{\mathbf{w}_t^{(\ell)}} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{y}}} \cdot \frac{\partial \hat{\mathbf{y}}}{\partial \boldsymbol{\xi}^{(N-1)}} \cdots \frac{\partial \boldsymbol{\xi}^{(\ell)}}{\partial \mathbf{w}_t^{(\ell)}}; \quad (21)$$

В современной литературе принята также более компактная форма записи уравнения (21):

$$\theta_{t+1} = \theta_t - \alpha \nabla_{\theta_t} \mathcal{L}(\theta_t). \quad (22)$$

В последние годы активно используются более современные методы для градиентного спуска. Один из наиболее эффективных методов оптимизации является алгоритм Adam [12], который является наиболее часто используемым методом в современных работах:

$$\begin{aligned} \mathbf{m}_0 &= \mathbf{0}, \quad \mathbf{v}_0 = \mathbf{0}; \\ \mathbf{m}_{t+1} &= \beta_1 \mathbf{m}_t + (1 - \beta_1) \nabla_{\theta_t} \mathcal{L}(\theta_t); \\ \mathbf{v}_{t+1} &= \beta_2 \mathbf{v}_t + (1 - \beta_2) [\nabla_{\theta_t} \mathcal{L}(\theta_t)]^2; \\ \hat{\mathbf{m}}_{t+1} &= \frac{\mathbf{m}_{t+1}}{1 - \beta_1^{t+1}}, \quad \hat{\mathbf{v}}_{t+1} = \frac{\mathbf{v}_{t+1}}{1 - \beta_2^{t+1}}; \\ \theta_{t+1} &= \theta_t - \alpha_t \frac{\hat{\mathbf{m}}_{t+1}}{\sqrt{\hat{\mathbf{v}}_{t+1} + \epsilon}}. \end{aligned} \quad (23)$$

Здесь  $\mathbf{m}_t$  и  $\mathbf{v}_t$  — оценки первого и второго моментов градиента,  $\beta_1 \in (0.5, 0.99)$ ,  $\beta_2 \in (0.8, 0.999)$  — коэффициенты затухания,  $\epsilon \sim 10^{-8}$  — малая константа для численной устойчивости,  $\hat{\mathbf{m}}_{t+1}$ ,  $\hat{\mathbf{v}}_{t+1}$  — скорректированные на смещение оценки. В ряде работ, посвящённым вычислительным экспериментам [8], метод Adam в среднем показывает наилучшую сходимость и точность по сравнению с другими алгоритмами оптимизации.

## 2.2 Архитектура обратимых нейронных сетей

Одним из фундаментальных ограничений стандартных полносвязных нейронных сетей, описанных в подразделе 2.3, является отсутствие свойства биективности. Поиск обратного отображения для стандартной нейронной сети является нетривиальной задачей. Более того, если размерность входного пространства  $M$  не равна размерности выходного пространства  $D$ , то биекция в строгом математическом смысле невозможна. Для решения этой проблемы применяются архитектуры обратимых нейронных сетей (Invertible Neural Networks, INN) [9, 10].

Основная идея INN заключается в построении априори обратимого отображения  $g : \mathcal{X} \rightarrow \mathcal{Y}$ , для которого существует точное аналитическое выражение для обратного преобразования  $f = g^{-1}$ . В основе таких сетей лежат так называемые «слои склейки» (coupling layers). Пусть входной вектор разбит на две части  $\mathbf{u} = [\mathbf{u}_1, \mathbf{u}_2]$ . Прямое преобразование  $\mathbf{v} = g(\mathbf{u})$  задается системой:

$$\mathbf{v}_1 = (\mathbf{u}_2 + \mathbf{t}_1(\mathbf{u}_1)) \otimes \exp(\mathbf{s}_1(\mathbf{u}_1)), \quad (24)$$

$$\mathbf{v}_2 = (\mathbf{u}_1 + \mathbf{t}_2(\mathbf{v}_1)) \otimes \exp(\mathbf{s}_2(\mathbf{v}_1)), \quad (25)$$

где оператор  $\otimes$  обозначает поэлементное произведение, а  $\mathbf{s}_1$ ,  $\mathbf{t}_1$ ,  $\mathbf{s}_2$ ,  $\mathbf{t}_2$  — произвольные нейросетевые функции. Обратное преобразование в этом случае вычисляется тривиально:

$$\mathbf{u}_1 = (\mathbf{v}_2 \otimes \exp(-\mathbf{s}_2(\mathbf{v}_1))) - \mathbf{t}_2(\mathbf{v}_1), \quad (26)$$

$$\mathbf{u}_2 = (\mathbf{v}_1 \otimes \exp(-\mathbf{s}_1(\mathbf{u}_1))) - \mathbf{t}_1(\mathbf{u}_1). \quad (27)$$

Чередование таких слоев с перестановками элементов вектора позволяет строить глубокие обратимые архитектуры.

### 2.2.1 Решение проблемы несовпадения размерностей

Описанная выше архитектура работает только в случае, когда размерности пространств  $\mathcal{X}$  и  $\mathcal{Y}$  равны. Если же приходится иметь дело с отображением из пространства большей размерности  $\mathcal{X}$  в пространство меньшей размерности  $\mathcal{Y}$ , то для сохранения биективности вводится латентное пространство  $\mathcal{Z} \in \mathbb{R}^K$ , где  $K = \dim(\mathcal{X}) - \dim(\mathcal{Y})$ . Предполагается, что латентное пространство имеет стандартное нормальное распределение:

$$\mathbf{Z} \sim p_{\mathbf{Z}}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}_K). \quad (28)$$

Таким образом, обучаемая модель реализует биективное отображение  $f_{\theta} : \mathcal{X} \rightarrow [\mathcal{Y}, \mathcal{Z}]$ .

### 2.2.2 Функция потерь и метод максимального правдоподобия

Согласно формуле замены переменной, плотность распределения входных данных  $p_{\mathcal{X}}(\mathbf{x})$  связана с плотностью распределения выходных через якобиан прямого преобразования:

$$p_{\mathcal{X}}(\mathbf{x}) = p_{\mathcal{Y}, \mathcal{Z}}(\mathbf{y}, \mathbf{z}) \cdot \left| \det \left( \frac{\partial f_{\theta}}{\partial \mathbf{x}} \right) \right|, \quad (29)$$

где  $\mathbf{y} = f_{\mathcal{Y}}(\mathbf{x}; \theta)$  и  $\mathbf{z} = f_{\mathcal{Z}}(\mathbf{x}; \theta)$  — компоненты прямого преобразования. Переходя к задаче минимизации, получаем суммарный функционал потерь:

$$\mathcal{L}(\theta) = \lambda_1 \mathcal{L}_y(\theta) + \lambda_2 \mathcal{L}_z(\theta), \quad (30)$$

где:

1.  $\mathcal{L}_y(\theta)$  отвечает за точность восстановления наблюдаемых данных (аналогично MSE в стандартных сетях):

$$\mathcal{L}_y(\theta) = \frac{1}{2} \|\mathbf{y}_{\text{true}} - \mathbf{y}_{\text{pred}}\|^2. \quad (31)$$

2.  $\mathcal{L}_z(\theta)$  выводится из условия соответствия латентного вектора априорному распределению. Логарифм правдоподобия для латентной компоненты имеет вид:

$$l_z(\theta) = \ln p_{\mathcal{Z}}(\mathbf{z}) + \ln \left| \det \left( \frac{\partial f_{\theta}}{\partial \mathbf{x}} \right) \right| = -\frac{1}{2} \|\mathbf{z}\|^2 + \ln |J_x|, \quad (32)$$

где использовано  $p_{\mathcal{Z}}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}_K)$ . Поскольку максимизация правдоподобия эквивалентна минимизации отрицательного логарифма, получаем:

$$\mathcal{L}_z(\theta) = -l_z(\theta) = \frac{1}{2} \|\mathbf{z}\|^2 - \ln |J_x|. \quad (33)$$

### 2.2.3 Эффективное вычисление якобиана

Ключевым преимуществом используемой архитектуры является возможность точного и эффективного вычисления определителя матрицы Якоби  $\mathbf{J} = \partial \mathbf{v} / \partial \mathbf{u}$ . Преобразование (24)–(25) может быть представлено как композиция двух последовательных отображений  $f_1$  и  $f_2$ . На первом этапе вектор  $\mathbf{u}_2$  масштабируется и сдвигается в зависимости от  $\mathbf{u}_1$ , что формирует блочно-треугольный якобиан  $\mathbf{J}_1$  с диагональю  $\text{diag}(\exp(\mathbf{s}_1(\mathbf{u}_1)))$ . На втором этапе аналогичное преобразование применяется к  $\mathbf{u}_1$  с использованием уже вычисленного промежуточного вектора, формируя блочно-треугольную структуру  $\mathbf{J}_2$  с диагональю  $\text{diag}(\exp(\mathbf{s}_2(\mathbf{v}_1)))$ .



Определитель полной матрицы Якоби равен произведению определителей составляющих:

$$|J_x| = |\mathbf{J}_1| \cdot |\mathbf{J}_2| = \prod_i \exp(s_1(\mathbf{u}_1)_i) \cdot \prod_i \exp(s_2(\mathbf{v}_1)_i) = \exp\left(\sum_i s_1(\mathbf{u}_1)_i + \sum_i s_2(\mathbf{v}_1)_i\right). \quad (34)$$

Логарифм определителя, необходимый для вычисления слагаемого  $\mathcal{L}_z(\theta)$ , определяется как простая сумма выходов подсетей  $\mathbf{s}_1$  и  $\mathbf{s}_2$ :

$$\ln |J_x| = \sum_i s_1(\mathbf{u}_1)_i + \sum_i s_2(\mathbf{v}_1)_i. \quad (35)$$

Таким образом, вычисление якобиана имеет линейную сложность  $O(d)$  и не требует формирования или обращения полных матриц частных производных. Итоговая функция потерь принимает вид:

$$\mathcal{L}(\theta) = \lambda_1 \|\mathbf{y}_{\text{true}} - \mathbf{y}_{\text{pred}}\|^2 + \lambda_2 \left( \frac{1}{2} \|\mathbf{z}\|^2 - \ln |J_x| \right), \quad (36)$$

что критически важно для эффективного обучения глубоких обратимых сетей методом стохастического градиентного спуска.

#### 2.2.4 Построение многослойной обратимой архитектуры

Одиночный обратимый слой преобразует лишь часть входного вектора, оставляя другую часть неизменной на данном шаге. Для повышения обобщающих способностей модели требуется использовать многослойную архитектуру. Полное преобразование  $f_\theta: \mathbf{X} \rightarrow [\mathbf{R}, \mathbf{Z}]$  представляется в виде композиции из  $L$  обратимых блоков:

$$f_\theta = f^{(L)} \circ P_{L-1} \circ f^{(L-1)} \circ \dots \circ P_1 \circ f^{(1)}, \quad (37)$$

где  $f^{(\ell)}$  —  $\ell$ -й обратимый слой вида (24)–(25), а  $P_\ell$  — оператор перестановки, применяемый между слоями. Перестановка гарантирует, что компоненты, зафиксированные на предыдущем шаге, будут трансформированы на последующих.

В каждом слое функции масштабирования  $\mathbf{s}_{1,2}^{(\ell)}$  и сдвига  $\mathbf{t}_{1,2}^{(\ell)}$  параметризуются многослойными персептронами. Поскольку выходы  $\mathbf{s}_{1,2}^{(\ell)}$  используются в экспоненте, на функции  $\mathbf{s}_{1,2}^{(\ell)}$  накладывается ограничение  $\tanh$  чтобы избежать взрывного роста или исчезновения градиентов при вычислении  $\exp(\mathbf{s}_{1,2}^{(\ell)})$ .

Обратимость всей композиции сохраняется автоматически: обратное преобразование вычисляется последовательным применением обратных шагов в обратном порядке:

$$f_\theta^{-1} = (f^{(1)})^{-1} \circ P_1^{-1} \circ \dots \circ P_{L-1}^{-1} \circ (f^{(L)})^{-1}. \quad (38)$$

Логарифм определителя Якобиана полной сети равен сумме логарифмов определителей отдельных слоёв:

$$\ln \left| \det \frac{\partial f_\theta}{\partial \mathbf{X}} \right| = \sum_{\ell=1}^L \ln \left| \det \frac{\partial f^{(\ell)}}{\partial \mathbf{u}^{(\ell-1)}} \right|, \quad (39)$$

что сохраняет линейную вычислительную сложность  $O(L \cdot d)$  и позволяет эффективно оптимизировать функционал (30) методами стохастического градиентного спуска без формирования полных матриц производных.

Глубина сети  $L$  и ширина подсетей выбираются эмпирически.

## 2.3 Подготовка данных

Для обучения нейросетевого аппроксиматора обратной задачи была сформирована выборка из пар  $(\mathbf{X}, \mathbf{R})$ , где  $\mathbf{X} = (E_1, \dots, E_4, \nu_1, \dots, \nu_4)$  — вектор упругих параметров функционально-градиентной полосы,  $\mathbf{R} = [r_k]_{k=1}^8$  — сеточная функция нормализованных контактных усилий, вычисленная алгоритмом [1].

### Разбиение выборки

Общий объём сгенерированной выборки составил 150 826 примеров. Данные были разделены на три непересекающихся подмножества:

- **Обучающая выборка** (120 826 примеров,  $\approx 80\%$ ) — используется для настройки весовых коэффициентов нейронной сети в процессе минимизации функционала потерь (18);
- **Валидационная выборка** (15 000 примеров,  $\approx 10\%$ ) — применяется для контроля переобучения, подбора гиперпараметров модели и ранней остановки обучения;
- **Тестовая выборка** (15 000 примеров,  $\approx 10\%$ ) — служит для финальной оценки обобщающей способности обученной модели на данных, не участвовавших в процессе обучения.

Такое разбиение позволяет объективно оценить качество модели и избежать ситуации, когда сеть «запоминает» обучающие примеры, но плохо работает на новых данных [4, 5].

### Подготовка данных

Перед подачей в нейронную сеть входные и целевые признаки подвергаются стандартизации с использованием  $Z$ -нормализации:

$$x' = \frac{x - \mu}{\sigma}, \quad (40)$$

где  $\mu$  и  $\sigma$  — выборочное среднее и стандартное отклонение признака  $x$ , вычисленные по обучающей выборке.

Параметры  $\mu$  и  $\sigma$ , вычисленные на обучающей выборке, сохраняются и применяются для масштабирования валидационной и тестовой выборок, что обеспечивает корректность оценки качества модели.

## 3 Численные решения.


### 3.1 Решение прямой задачи с помощью

#### Мотивация

В случае существования биективного отображения, точность решения обратной задачи идентификации упругих параметров функционально-градиентной полосы должна напрямую зависеть от точности аппроксимации прямого отображения  $\mathcal{F}_{\text{direct}}: \mathbf{X} \mapsto \mathbf{R}$ . Чем точнее нейросетевая модель воспроизводит зависимость между входными параметрами материала  $\mathbf{X} = (E_1, \dots, E_4, \nu_1, \dots, \nu_4)$  и выходными сеточными функциями нормализованных контактных усилий  $\mathbf{R} = [r_k]_{k=1}^8$ , тем более устойчивым и точным будет восстановление параметров в обратной задаче.

### 3.1.1 Архитектура модели

Для аппроксимации отображения  $\mathcal{F}_{\text{direct}}$  используется полносвязная нейронная сеть с функциями активации. Архитектура нейронной сети представлена в таб. (1).



**Рис. 3:** Динамика изменения функции потерь при обучении обратимой нейронной сети без латентного пространства на первых 200 эпохах

Модель реализована на базе фреймворка PyTorch. Оптимизация параметров сети осуществлялась методом Adam (23) с начальным шагом обучения  $\alpha = 10^{-3}$ , который постепенно уменьшался до  $\alpha = 10^{-5}$ .

### 3.1.2 Результаты обучения

Обучение проводилось на протяжении 300 эпох, в результате были достигнуты результаты, представленные в таблице (6):

**Таблица 2:** Метрики качества аппроксимации прямой задачи на тестовой выборке

| Метрика          | Значение              | Интерпретация                          |
|------------------|-----------------------|----------------------------------------|
| $R^2$            | 1.0000                | Коэффициент детерминации               |
| $L1\text{-norm}$ | $1.38 \times 10^{-4}$ | Нормированная абсолютная погрешность   |
| $L2\text{-norm}$ | $1.98 \times 10^{-4}$ | Нормированная квадратичная погрешность |

Значение  $R^2 = 1.0000$  (с точностью до машинного округления) свидетельствует о практически идеальном воспроизведении целевой переменной  $\mathbf{R}$  по входным параметрам  $\mathbf{X}$ . Столь высокая точность обусловлена детерминированным характером прямой задачи и отсутствием шумов в данных, полученных численным алгоритмом [1].

На рис. 3 представлена зависимость значения функции потерь от номера эпохи обучения.

### Промежуточный вывод

Построенная нейросетевая модель обеспечивает высокоточную аппроксимацию прямого отображения  $\mathcal{F}_{\text{direct}}$  с погрешностью, близкой к машинному нулю. Это создаёт надёжную


основу для решения обратной задачи: наличие прямого отображения даёт надежду на существование хорошего обратного отображения в случае биективности решения.

## 3.2 Обратимые нейронные сети без латентного пространства

### 3.2.1 Архитектура

Был рассмотрен случай, где размерности входного и выходного пространств совпадают, и отображение  $f_\theta: \mathbf{X} \rightarrow \mathbf{R}$  реализуется непосредственно через композицию обратимых блоков. Была предложена архитектура, в которой функции  $\mathbf{s}_{1,2}^\ell(\cdot)$  и  $\mathbf{t}_{1,2}^\ell(\cdot)$  параметризуются многослойными персептронами с архитектурами, представленными в таблице (3). Ограничение выхода  $\mathbf{s}_{1,2}^\ell(\cdot)$  играет критическую роль для численной устойчивости обратимой архитектуры. Поскольку масштабирование в прямом и обратном проходах осуществляется через  $\exp(\mathbf{s}_{1,2}^\ell)$  и  $\exp(-\mathbf{s}_{1,2}^\ell)$ , соответственно, неограниченные значения  $\mathbf{s}_{1,2}^\ell$  могут приводить к взрыву или исчезновению градиентов. Диапазон  $[-3, 3]$  обеспечивает  $\exp(\mathbf{s}_{1,2}^\ell) \in [e^{-3}, e^3] \approx [0.05, 20.08]$ .

Для улучшения репрезентативных свойств, была предложена многослойная обратимая нейронная сеть с числом слоев  $L = 4$ , в соответствии с выражением (37). На каждом из слоев, персептроны  $\mathbf{s}_{1,2}^\ell$  и  $\mathbf{t}_{1,2}^\ell$  удовлетворяют архитектуре (3). Процесс обучения (на первых 200 эпохах) представлен на рисунке (4).



**Рис. 4:** Динамика изменения функции потерь при обучении обратимой нейронной сети без латентного пространства на первых 200 эпохах

| Слой                                                | Размерность         | Ограничение            |
|-----------------------------------------------------|---------------------|------------------------|
| <b>Подсети <math>\mathbf{s}_{1,2}(\cdot)</math></b> |                     |                        |
| Вход                                                | 4                   | —                      |
| Linear                                              | $4 \rightarrow 16$  | GELU                   |
| Linear                                              | $16 \rightarrow 16$ | GELU                   |
| Выходной                                            | $16 \rightarrow 4$  | $3 \cdot \tanh(\cdot)$ |
| <b>Подсети <math>\mathbf{t}_{1,2}(\cdot)</math></b> |                     |                        |
| Вход                                                | 4                   | —                      |
| Linear                                              | $4 \rightarrow 32$  | GELU                   |
| Linear                                              | $32 \rightarrow 16$ | GELU                   |
| Выходной                                            | $16 \rightarrow 4$  | Линейная               |

**Таблица 3:** Архитектура подсетей

### 3.2.2 Результаты обучения

Модель реализована на базе фреймворка PyTorch. Оптимизация параметров сети осуществлялась методом Adam (23) с начальным шагом обучения  $\alpha = 10^{-3}$ , который постепенно уменьшался до  $\alpha = 10^{-7}$  за 2000 эпох обучения. В результате достигнуты результаты, представленные в таблице (4):

| Метрика                | Значение              | Интерпретация                          |
|------------------------|-----------------------|----------------------------------------|
| <b>Прямой проход</b>   |                       |                                        |
| $R^2$                  | 0.99                  | Коэффициент детерминации               |
| $L1\text{-norm}$       | $7.83 \times 10^{-3}$ | Нормированная абсолютная погрешность   |
| $L2\text{-norm}$       | $9.69 \times 10^{-3}$ | Нормированная квадратичная погрешность |
| <b>Обратный проход</b> |                       |                                        |
| $R^2$                  | 0.45                  | Коэффициент детерминации               |
| $L1\text{-norm}$       | $1.44 \times 10^{-1}$ | Нормированная абсолютная погрешность   |
| $L2\text{-norm}$       | $1.90 \times 10^{-1}$ | Нормированная квадратичная погрешность |

**Таблица 4:** Метрики качества аппроксимации прямой задачи на тестовой выборке

### Промежуточный вывод

Одной из причин слабых обобщающих способностей выбранной модели может являться шум в данных. Удаление данного шума должно увеличить репрезентативные способности нейронной сети, однако, это вынуждает понижать размерность векторов  $\mathbf{R}$ , и, соответственно, делает невозможным использование обратимых нейронных сетей без латентного пространства.

## 3.3 Обратимые нейронные сети с латентным пространством

### 3.3.1 Метод главных компонент

Одной из причин плохих обобщающих способностей нейросети, представленной в главе (3.2) является мультиколлинеарность в  $\mathbf{R}$ . В качестве решения данной проблемы может быть рассмотрен алгоритм сжатия данных, который называется методом главных компонент (Principal component analysis, PCA [4]).

Данный метод основан на, основанный на сингулярном разложении матрицы (Singular Value Decomposition, SVD [4]): любая прямоугольная матрица  $\mathbf{A}$  размерности  $m \times n$ , может быть представлена, как

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^T, \quad (41)$$

где  $\mathbf{U}$  и  $\mathbf{V}$  — унитарные матрицы, а  $\mathbf{\Lambda}$  — диагональная. Более того, оказывается, что:

- диагональные элементы матрицы  $\mathbf{\Lambda}$  совпадают с  $\sigma_1, \dots, \sigma_m$ , сингулярными значениями матрицы  $\mathbf{A}$  (т.е. арифметическими значениями квадратных корней из собственных значений матриц  $\mathbf{A}\mathbf{A}^T$ );
- столбцы матриц  $\mathbf{U}$  и  $\mathbf{V}^T$  совпадают с собственными векторами матриц  $\mathbf{A}\mathbf{A}^T$  и  $\mathbf{A}^T\mathbf{A}$ , соответственно, и образуют ортогональные базисы.

Для определённости будем считать, что  $\sigma_1, \dots, \sigma_m$  расставлены на диагонали в порядке убывания. Пусть  $\mathbf{\Lambda}_d$  — главный минор  $d$ -ого порядка матрицы  $\mathbf{\Lambda}$ . Если начиная с какого-то  $\sigma_d$  сингулярные значения становятся достаточно малы, то  $\mathbf{A} \cong \mathbf{U}\mathbf{\Lambda}_d\mathbf{V}$ . Тогда можно отобразить матрицу  $\mathbf{A}$  на пространство размерности  $d$  с базисными векторами — столбцами главного минора  $d$ -ого порядка  $\mathbf{V}_d$  матрицы  $\mathbf{V}$ , получается матрица  $\mathbf{Z}$ :

$$\mathbf{Z} = \mathbf{A}\mathbf{V}_d. \quad (42)$$

Тогда оператор  $F(\mathbf{x})$ , сжимающий данные, и обратный ему  $G(\mathbf{z})$  описываются как:

$$F(\mathbf{x}) = V_d^T \mathbf{x}, \quad (43)$$


$$G(\mathbf{z}) = V_d \mathbf{z}. \quad (44)$$

Таким образом возможно уменьшить размерность данных, оставив только наиболее значимые компоненты и избавившись от шума в данных. В данной работе удалось преобразовать  $\mathbf{R} \in \mathbb{R}^8$  в  $\hat{\mathbf{R}} \in \mathbb{R}^4$  потеряв менее 1% точности при восстановлении данных.

### 3.3.2 Архитектура

Также, как и в предыдущем случае, отображение  $f_\theta: \mathbf{X} \rightarrow [\hat{\mathbf{R}}, \mathbf{Z}]$ , где  $\hat{\mathbf{R}}$  получено из  $\mathbf{R}$  при помощи преобразования (43), а  $\mathbf{Z} \in \mathcal{N}(0, 1)$ , как описано в разделе (2.2.1), реализуется через композицию обратимых блоков. Функции  $\mathbf{s}_{1,2}^\ell(\cdot)$  и  $\mathbf{t}_{1,2}^\ell(\cdot)$  параметризуются многослойными персептронами с архитектурами, представленными в таблице (5). Отметим, что на выходы  $\mathbf{s}_{1,2}^\ell(\cdot)$  накладываются такие же ограничения, как и в случае без латентного пространства.

Получившаяся многослойная обратимая нейронная сеть с числом слоев  $L = 6$  имеет на каждом из уровней персептроны  $\mathbf{s}_{1,2}^\ell$  и  $\mathbf{t}_{1,2}^\ell$ , которые удовлетворяют архитектурам, предложенным в таблице (5). Процесс обучения представлен на рисунке (5).



**Рис. 5:** Динамика изменения функции потерь при обучении обратимой нейронной сети с латентным пространством

| Слой                                                | Размерность          | Ограничение            |
|-----------------------------------------------------|----------------------|------------------------|
| <b>Подсети <math>\mathbf{s}_{1,2}(\cdot)</math></b> |                      |                        |
| Вход                                                | 4                    | —                      |
| Linear                                              | 4 $\rightarrow$ 64   | GELU                   |
| Linear                                              | 64 $\rightarrow$ 32  | GELU                   |
| Выходной                                            | 32 $\rightarrow$ 4   | $3 \cdot \tanh(\cdot)$ |
| <b>Подсети <math>\mathbf{t}_{1,2}(\cdot)</math></b> |                      |                        |
| Вход                                                | 4                    | —                      |
| Linear                                              | 4 $\rightarrow$ 128  | GELU                   |
| Linear                                              | 128 $\rightarrow$ 64 | GELU                   |
| Linear                                              | 64 $\rightarrow$ 32  | GELU                   |
| Выходной                                            | 32 $\rightarrow$ 4   | Линейная               |

**Таблица 5:** Архитектура подсетей

### 3.3.3 Результаты обучения

Модель реализована на базе фреймворка PyTorch. Оптимизация параметров сети осуществлялась методом Adam (23) с начальным шагом обучения  $\alpha = 10^{-3}$ , который постепенно уменьшался до  $\alpha = 10^{-7}$ . После 600 эпох обучения на тестовой выборке были достигнуты результаты, показанные в таблице (6).

### Предварительный вывод

Данная архитектура показала прирост качества относительно предыдущей версией. Удаление шума при помощи метода главных компонент помогло значительно улучшить обобщающие способности нейронной сети.

**Таблица 6:** Метрики качества аппроксимации прямой задачи на тестовой выборке

| Метрика                | Значение              | Интерпретация                          |
|------------------------|-----------------------|----------------------------------------|
| <b>Прямой проход</b>   |                       |                                        |
| $R^2$                  | 0.99                  | Коэффициент детерминации               |
| $L1\text{-norm}$       | $3.83 \times 10^{-3}$ | Нормированная абсолютная погрешность   |
| $L2\text{-norm}$       | $4.69 \times 10^{-3}$ | Нормированная квадратичная погрешность |
| <b>Обратный проход</b> |                       |                                        |
| $R^2$                  | 0.67                  | Коэффициент детерминации               |
| $L1\text{-norm}$       | $7.34 \times 10^{-2}$ | Нормированная абсолютная погрешность   |
| $L2\text{-norm}$       | $9.91 \times 10^{-2}$ | Нормированная квадратичная погрешность |

## Вывод

В данной работе исследована возможность применения обратимых нейронных сетей для решения обратной задачи идентификации упругих параметров функционально-градиентной полосы по данным коллективного индентирования. На основе численных экспериментов получены следующие основные результаты:

1. **Аппроксимация прямой задачи.** Многослойный персептрон обеспечивает высокоточную аппроксимацию отображения  $\mathcal{F}_{\text{direct}} : \mathbf{X} \mapsto \mathbf{R}$ .
2. **Обратимые сети без латентного пространства.** Архитектура INN с биективным отображением  $\mathbf{X} \rightarrow \mathbf{R}$  продемонстрировала удовлетворительную точность в прямом проходе, однако качество восстановления параметров в обратном проходе оказалось ограниченным. Основной причиной является мультиколлинеарность компонент вектора  $\mathbf{R}$  и чувствительность архитектуры к шуму в данных.
3. **Обратимые сети с латентным пространством.** Применение метода главных компонент позволило снизить размерность выходного пространства с 8 до 4 компонент при потере менее 1% информации. Архитектура INN с латентным пространством показала улучшение качества обратного восстановления, что подтверждает эффективность удаления шума в данных и добавления латентных переменных для компенсации неопределённости, возникающей при отображении из пространства большей размерности в пространство меньшей размерности.

**Закключение.** Разработанный подход на основе обратимых нейронных сетей с латентным пространством демонстрирует потенциал для решения обратных задач механики контактного взаимодействия.

## Список литературы

- [1] *Бобылев А.А.* Задача коллективного индентирования упругой полуплоскости системой жестких штампов, упруго связанных с общей платформой // Прикл. матем. и механика. 2025. Т. 89. № 2. С. 280–294.
- [2] *Бобылев А.А.* Задача одностороннего дискретного контакта для функционально-градиентной упругой полосы // Вест. Моск. ун-та. Сер. 1. Матем. Механ. 2024. № 2. С. 58–69.
- [3] *Хайкин С.* Нейронные сети: полный курс. М.: Вильямс, 2002. С. 500–540.
- [4] *Cherkassky V., Mulier F.* Learning from Data: Concepts, Theory, and Methods. 2nd ed. John Wiley & Sons, 2007. P. 249–284.
- [5] *Chollet F.* Deep Learning with Python. СПб.: Питер, 2018. С. 100–400.
- [6] *Yagava G., Onishi A.* Computational Mechanics with Deep Learning. Lecture Notes on Numerical Methods in Engineering and Sciences., 2022. P. 10–150.
- [7] *Helton J.C., Davis F.J.* Latin Hypercube Sampling and the Propagation of Uncertainty in Analyses of Complex Systems. // Sandia Report, 2022.
- [8] *Choi D., Shallue C.J., Nado Z., Lee J., Maddison C.J., Dahl G.E.* On Empirical Comparisons of Optimizers for Deep Learning., 2020.
- [9] *Ardizzone L., Lüth C., Kruse J., Rother C., Köthe U.* Guided Image Generation with Conditional Invertible Neural Networks. // Visual Learning Lab Heidelberg, 2019.
- [10] *Ardizzone L., Kruse J., Wirkert S., Rahner D., Pellegrini E.W., Klessen R.S., Maier-Hein L., Rother C., Köthe U.* Analyzing Inverse Problems with Invertible Neural Networks. // Proc. of the 7th Int. Conf. on Learning Representations (ICLR 2019), 2019.
- [11] *Kruse J., Ardizzone L., Rother C., Köthe U.* Benchmarking Invertible Architectures on Inverse Problems., 2021.
- [12] *Diederik P. Kingma, Jimmy Lei Ba.* Adam: a method for stochastic optimization., 2015